

ИТОГОВЫЙ ПРОЕКТ

Анализ влияния финансовых новостей на российский фондовый рынок

NLP + Time Series Analysis

Смыков Артемий
DS-20

Цель и гипотезы исследования

ЦЕЛЬ

Исследовать, связана ли тональность финансовых новостей с движением российского фондового рынка, и можно ли использовать её для прогнозирования направления цены на следующий торговый день.

H1 — ПОДТВЕРЖДЕНА ✓

Тональность финансовых новостей статистически значимо коррелирует с доходностью акций в тот же торговый день.

$r = 0.097-0.169$, $p < 0.05$
для всех 6 инструментов

H2 — НЕ ПОДТВЕРЖДЕНА ✗

Сентимент вчерашних новостей помогает предсказать завтрашнее направление рынка.

Тест Грейнджера: $p > 0.05$
для всех тикеров и лагов 1–3 дня

Источники данных

НОВОСТНОЙ ДАТАСЕТ

RussianFinancialNews (Kaggle, Apache 2.0)

91 955 новостей → после фильтрации **61 398**

SmartLab	26 404
BCS	5 652
Finam	15 662
BCS Tech	4 373
RDV	4 838
T-Analytic / T-Invest	4 469

РЫНОЧНЫЕ ДАННЫЕ

MOEX ISS API

Дневные котировки

MOEX	Индекс МБ	553д
SBER	Сбербанк	553д
GAZP	Газпром	553д
LKOH	Лукойл	553д
PLZL	Полюс	553д
YDEX	Яндекс	526д

61 398

новостей

553


торговых дня

6


инструментов

Разведочный анализ: новостной корпус

Доля источников



Упоминания компаний в
новостях



441 симв

средняя длина текста


49.5%

новостей без заголовка (Telegram)

2022–2024

период после фильтрации

Разведочный анализ: рыночные данные



Количество новостей ≠ движение рынка

Первая проверка: связано ли количество новостей с доходностью МОЕХ?

Pearson $r = 0.052$ · Spearman $r = 0.060$ → практически нет связи



Количество не важно

Много новостей в день не означает сильное движение рынка. Рынок может игнорировать поток информации.



Важна тональность

Не сколько новостей вышло, а что в них написано — позитивное или негативное. Это мотивирует NLP-анализ.




Переходим к NLP

Следующий шаг — присвоить каждой новости оценку тональности и проверить связь уже с сентиментом.

Вывод: для выявления влияния новостей на рынок необходим анализ тональности, а не просто подсчёт количества

Анализ тональности 61 398 новостей



■ Нейтральный 89% ■ Негативный 8.1%
■ Позитивный 2.9%

МОДЕЛЬ

seara/rubert-tiny2-russian-sentiment

RuBERT · 117 MB · 3 класса · CPU-совместима

ПРИМЕРЫ РАЗМЕТКИ

POSITIVE

"Сбербанк показал рекордную прибыль"

NEGATIVE

"Газпром потерял европейский рынок"

NEUTRAL

"Торги прошли в штатном режиме"

80%

дней с отриц. сентиментом

-0.052

средний сентимент

~10 мин

время разметки на CPU

Технические индикаторы из котировок

return_1d / 2d / 5d

Дневная доходность за 1, 2 и 5 торговых дней (%)

return_lag1/2/3

Лаги доходности — доходность 1, 2, 3 дня назад

ma5 / ma10 / ma20

Скользящие средние цены за 5, 10 и 20 дней

price_to_ma5/20

Отклонение цены от скользящей средней (сигнал тренда)

rsi

Индекс относительной силы RSI-14
(перекупленность/перепроданность)

volatility_5d/20d

Скользящее стандартное отклонение доходности за 5 и 20 дней

volume_ratio

Отношение объёма торгов к скользящему среднему объёма
(активность)

target

Целевая переменная: 1 = рост завтра, 0 = падение или стагнация

Признаки тональности с лагами

ЛОГИКА ЛАГОВ: мы не можем знать тональность сегодняшних новостей в момент открытия рынка — используем только прошлое



АГРЕГАЦИИ ЗА ДЕНЬ

- sentiment_mean — средняя тональность
- sentiment_net — позитивные минус негативные
- positive_ratio / negative_ratio — доли классов
- news_count — количество новостей

ЛАГИ (1, 2, 3 ДНЯ)

- sentiment_mean_lag1/2/3
- sentiment_net_lag1/2/3
- positive_ratio_lag1
- negative_ratio_lag1

СКОЛЬЗЯЩИЕ СРЕДНИЕ

- sentiment_ma3 — МА за 3 дня
- sentiment_ma7 — МА за 7 дней
- sentiment_ma14 — МА за 14 дней
- sentiment_change1/3 — изменение сентимента

Итого: 23 признака (11 рыночных + 12 новостных) · ~533 строки на тикер · баланс классов ~50/50

Тональность статистически связана с доходностью




✓ Все 6 тикеров: $p < 0.05$ · Сильнейшая корреляция: PLZL $r=0.169$ · Слабейшая: GAZP $r=0.097$

Причинность с задержкой не подтверждена

H_0 : sentiment предыдущих дней НЕ помогает предсказывать завтрашнюю доходность

Если $p > 0.05$ — нулевая гипотеза не отвергается → sentiment прошлых дней бесполезен для прогноза

p-value теста Грейнджера по тикерам и лагам




ПОРОГ
 $p < 0.05$

Все значения
значительно
выше порога →
 H_0 не
отвергается

Рынок мгновенно отыгрывает новости — эффект не переносится на следующий день → Гипотеза эффективного рынка Фамы

От baseline к ансамблям



Baseline:

Всегда предсказывать рост → ROC-AUC ~0.50.
Минимальная планка для любой модели

LR + сентимент:

Для 5 из 6 тикеров добавление сентимента ухудшило результат. Линейная модель не справляется с коррелированными признаками

Лучший результат:

Random Forest: средний 0.517. XGBoost лучший для YDEX (0.614) но нестабилен на других тикерах

LSTM — нейросеть с памятью

ПОЧЕМУ LSTM



Финансовые ряды зависят от истории. LSTM имеет внутреннюю память и сам учится какую информацию из прошлых дней сохранить.

АРХИТЕКТУРА

Вход: 10 дней × 23 признака

LSTM: 2 слоя, 64 нейрона, dropout 0.5


Выход: вероятность роста (0–1)



Early Stopping: patience 15 эпох — модель останавливается в лучшей точке, не переобучаясь · **GPU:** NVIDIA T4, Google Colab

LSTM превосходит все классические модели

LSTM ROC-AUC по тикерам



0.606

средний ROC-AUC

0.655



лучший (GAZP)

+0.089

прирост vs RF

LSTM 0.606 > RF 0.517 > LR+цент 0.511 > XGBoost 0.504 > LR 0.498 ≈ Baseline 0.500

Сравнение всех моделей



0.606 LSTM (победитель)

0.517 Random Forest

0.498 LR (только рынок)

Что показало исследование

01

Сентимент новостей статистически значимо коррелирует с доходностью акций в тот же день ($r=0.10-0.17$, $p<0.05$ для всех 6 тикеров). H1 подтверждена.

02

Предсказательной силы с задержкой нет — тест Грейнджера показал $p>0.05$ для всех тикеров и лагов. Рынок мгновенно отыгрывает новости. H2 отклонена.

03

LSTM (ROC-AUC 0.606) значительно превосходит классические модели (0.50–0.52). Учёт временных зависимостей принципиально важен для задачи.

04

Рынок рос вопреки негативному фону (80% дней — отрицательный сентимент). Участники адаптировались к хроническому негативу 2022–2024.

Как можно улучшить результаты

Увеличить объём
данных

Добавить
макрэкономические
факторы

Специализированная
финансовая модель
тональности

Walk-Forward
Validation

Спасибо за внимание